

模型评测方案 — 高难度数据集与工具调用

2026-09-17 | 模型测试平台

总结

对 DSV4-Flash-0731-256K 与 DSV4-Flash-0731-1M 两款模型，通过外部 API 直连、多模型并行评测，共设 **3 个测试用例**，覆盖高难度知识推理与工具调用两条主线：



- **用例一 · 常规准确率**：两模型并行跑 6 个数据集（GSM8K / GPQA / MMLU-Pro / HLE / HMMT / LiveCodeBench），抽样 200、并发 2，本机执行；判分客观题准确率 + 代码沙箱通过率。
- **用例二 · 工具调用（真实容器）**：Terminal-Bench 2.1 与 SWE-bench 各 10 题，并发 1，在远端 x86 节点执行；判分任务完成率 / 单测通过率。
- **用例三 · 工具调用（纯 API）**：BFCL-v4 与 τ^2 -bench，并发 4，本机执行；判分函数/参数匹配。
- **数据与工具选型**：数据集按"基线—高难—天花板"分层、均选防污染抗检索的权威基准；工具调用配 EvalScope / Harbor / swebench 工具链与 x86 评测节点。
- **评测完成**：两模型已完成全部 8 项基准的并排实测，成绩与显著性检验见第六章；结论为 256K 整体略优，其中 GPQA 差距统计显著。

一、模型接入

项目	说明
评测对象	DSV4-Flash-0731-256K、DSV4-Flash-0731-1M
接入方式	外部 API 直连（OpenAI 兼容），不做本地部署
调度	多模型并行、断点续跑、结果统一对比


二、数据集选型

测试集	能力维度	难度	规模	来源	选型依据
HLE	跨学科推理	极高	2500	HuggingFace / cais_hle	前沿天花板，答案抗搜索
GPQA Diamond	研究生理科	高	198	ModelScope / GPQA_Diamond	博士级理科，抗检索
MMLU-Pro	通用知识推理	高	12032	ModelScope / MMLU-Pro	10 选项，低猜测率
HMMT 2025	竞赛数学	极高	30	ModelScope / evalscope_hmmt	最新竞赛真题
LiveCodeBench	代码生成	高	1055	evalscope / LiveCodeBench	滚动出新题，沙箱判题
GSM8K（基线）	基础数学	标准	1319	ModelScope / evalscope_gsm8k	监控基础能力



三、工具调用评测

测试集	考察能力	规模	来源	工具链	执行环境
Terminal-Bench 2.1	终端多步任务	89	Harbor / Terminal-Bench-2.1	EvalScope + Harbor (terminus-2)	x86 容器
SWE-bench Verified Mini	软件工程修复	50	HuggingFace / SWE-bench_Verified	EvalScope + swebench (native)	x86 容器
BFCL-v4	函数调用	2000	Berkeley / BFCL-v4	EvalScope (16 子集)	本机
τ^2 -bench	工具对话	165	Sierra / tau2-bench	EvalScope (airline/retail)	本机




四、测试用例

用例	模型	测试集 / 抽样	并发	判分	执行位置	状态
常规准确率	256K vs 1M	GSM8K / GPQA / MMLU-Pro / HLE 各 200；HMMT25 30；LiveCodeBench 200	2	准确率；代码沙箱通过率	本机	已完成
工具调用	256K vs 1M	Terminal-Bench 10；SWE-bench 10	1	任务完成率；单测通过率	远端 x86 节点	已完成
纯 API 工具调用	256K vs 1M	BFCL-v4； τ^2 -bench	4	函数/参数匹配	本机	待测

五、执行与评分

维度	常规问答	纯 API 工具调用	真实容器 Agent
执行位置	本机	本机	远端 x86 节点
判分	准确率	函数/参数匹配	任务完成 / 单测通过
并发	2	4	1

两模型实测成绩对比 (* 仅 GPQA 差异显著)



六、实测结果

公平性验证：evalscope 的 reviews 文件保存每题完整 prompt。对每题取全部非 assistant 消息内容计算 MD5 哈希作为「题目指纹」，比对两模型同一数据集的指纹集合；工具调用基准按 SWE 实例 ID (django__django-*) 与 Terminal 任务名 (harbor trial) 比对。结果：8 项基准的题目集合**完全一致**（GSM8K 200/200、GPQA 198/198、MMLU-Pro 210/210、HLE 125/125、LiveCodeBench 200/200、HMMT25 30/30、SWE 10 实例、Terminal 10 任务），两模型做的是同一批题，对比公平。

数据集	实测题数	256K	1M	差值	p 值†
GSM8K	200	97.50%	96.50%	+1.00	0.625
GPQA	198 (全量)	69.19%	61.62%	+7.57	0.008
MMLU-Pro	210	81.43%	79.52%	+1.91	0.344
HMMT25	30	60.00%	53.33%	+6.67	0.688
HLE	125	11.50%	13.00%	-1.50	0.774
LiveCodeBench	200	68.50%	67.00%	+1.50	0.678
SWE-bench Mini	10	70.00%	60.00%	+10.00	1.000
Terminal-Bench 2.1	10	0.00%	0.00%	0	1.000

† McNemar 精确检验（问题配对、逐题二值结果； $p < 0.05$ 为显著）。

结论： - 256K 8 项中 6 项占优，但**仅 GPQA 差距统计显著** ($p=0.008$, 198 题中净多答对 15 题)，其余差异在现有样本量下均属随机波动范围。 - SWE-bench +10pp 仅 10 题，样本偏小，建议扩至 30-50 题复核。 - Terminal-Bench 双 0：10/10 任务真实跑完（单任务约 15-25 分钟）后聚合为 0，非环境故障；失败集中于命令超时，且当前配置 max_turns=50 低于官方默认 200，建议放宽后复核。 - 1M 版常规基准略低于 256K，属长上下文扩展（RoPE/上下文训练）的常见折衷，非测试偏差。 - 耗时：常规 256K 约 2h、1M 约 5h；工具调用两模型各约 5h。